



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS QUIXADÁ
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

DÉCIO GONÇALVES DE AGUIAR NETO

**TRANSFERÊNCIA DE CONHECIMENTO UTILIZANDO APRENDIZADO
PROFUNDO PARA CLASSIFICAÇÃO DE IMAGENS HISTOPATOLÓGICAS**

QUIXADÁ
2017

DÉCIO GONÇALVES DE AGUIAR NETO

TRANSFERÊNCIA DE CONHECIMENTO UTILIZANDO APRENDIZADO PROFUNDO
PARA CLASSIFICAÇÃO DE IMAGENS HISTOPATOLÓGICAS

Monografia apresentada no curso de Ciência da Computação da Universidade Federal do Ceará, como requisito parcial à obtenção do título de bacharel em Ciência da Computação. Área de concentração: Computação.

Orientador: Prof. Dr. Paulo de Tarso Guerra Oliveira

QUIXADÁ

2017

Dados Internacionais de Catalogação na Publicação
Universidade Federal do Ceará
Biblioteca Universitária
Gerada automaticamente pelo módulo Catalog, mediante os dados fornecidos pelo(a) autor(a)

- N385t Neto, Décio Gonçalves de Aguiar.
Transferência de conhecimento utilizando aprendizado profundo para classificação de imagens
histopatológicas / Décio Gonçalves de Aguiar Neto. – 2017.
30 f. : il. color.
- Trabalho de Conclusão de Curso (graduação) – Universidade Federal do Ceará, Campus de Quixadá,
Curso de Ciência da Computação, Quixadá, 2017.
Orientação: Prof. Dr. Paulo de Tarso Guerra Oliveira.
1. Aprendizagem Profunda. 2. Transferência de Aprendizagem. 3. Classificação. 4. Biópsia. I. Título.
CDD 004
-

DÉCIO GONÇALVES DE AGUIAR NETO

TRANSFERÊNCIA DE CONHECIMENTO UTILIZANDO APRENDIZADO PROFUNDO
PARA CLASSIFICAÇÃO DE IMAGENS HISTOPATOLÓGICAS

Monografia apresentada no curso de Ciência da Computação da Universidade Federal do Ceará, como requisito parcial à obtenção do título de bacharel em Ciência da Computação. Área de concentração: Computação.

Aprovada em: ____/____/____

BANCA EXAMINADORA

Prof. Dr. Paulo de Tarso Guerra Oliveira (Orientador)
Universidade Federal do Ceará – UFC

Prof. Dr. Cristiano Bacelar de Oliveira
Universidade Federal do Ceará - UFC

Prof. Me. Carlos Igor Ramos Bandeira
Universidade Federal do Ceará - UFC

A minha avó Ana.

AGRADECIMENTOS

Agradeço primeiramente a Deus, por sempre me iluminar e me guiar em todas as escolhas da vida.

A minha avó Ana, por ter me acolhido, cuidado e me apresentado o caminho da fé, por toda sua dedicação e carinho, o meu muito obrigado.

A minha família por todo o apoio e suporte durante os anos de graduação.

Ao meu orientador Paulo de Tarso, por todas as conversas, incentivos e por toda a paciência e dedicação, e por ter aceitado o desafio que foi este trabalho, o meu mais sincero obrigado.

Aos professores Cristiano e Carlos Igor, que compuseram a banca deste trabalho, e puderam contribuir tão significativamente para a melhoria e engrandecimento deste trabalho.

Aos professores Joel Ramiro, Lucas Ismaily e Wladimir Tavares, que se mostraram grandes exemplos a serem seguidos e grandes amigos durante esses anos de graduação, incentivando e guiando diariamente para uma melhor formação.

Aos meus amigos Arthur Antunes, Mateus Pinheiro, Gabriel Gomes e Ycaro Melo, vocês foram parte fundamental em grandes conquistas de minha vida, e agora em mais um ciclo, se mostraram companheiros fiéis e verdadeiros irmãos que a vida me deu.

Aos meus amigos, irmãos e irmã de graduação, João Vitor, Ronildo, Raul, Daiane, Ana Paula, Salathiel, Marcelo, Leonardo e Dieinison, foi uma honra compartilhar estes anos ao lado de todos vocês, obrigado por todos os bons momentos e por toda a ajuda.

Aos Computeiros do Zodíaco e Juliana, vocês tornaram esses anos muito mais agradáveis e minhas manhãs mais cheias de alegria, a vocês meus amigos e amiga, meu muito obrigado.

Aos habitantes da casa número 24, Antônio Raimundo, Felipe, Iury e Rafaella, muito obrigado por todos os bons momentos e por todas as vezes que fui tão bem acolhido em vossa residência.

Aos meus amigos de EC, vocês foram meu segundo curso e foram grandes companheiros nessa jornada de formação em ciênciaria, a todos vocês, meu muito obrigado.

A minha família maçônica Deus e Universo N8, meu muito obrigado, por todas as alegrias, ensinamentos, incentivo e conforto que tive por todos os que fazem essa grande família.

Ao campus da UFC Quixadá que foi meu lar durante esses 4 anos e que agora me despeço, muito obrigado por todos os ensinamentos, por todas as noites mal dormidas e pelo apoio e dedicação de todos que fazem parte dessa instituição, meu caloroso obrigado.

E agradeço a todos que fizeram parte deste ciclo, que direta ou indiretamente ajudaram em minha formação, essa vitória é de cada um de vocês.

"A verdadeira qualidade de um shinobi não está no número de jutsus ou na quantidade de talento que ele possui, o importante é a determinação de nunca desistir"

(Jiraya)

RESUMO

No presente trabalho, os autores fazem uma investigação sobre o uso de transferência de conhecimento aplicado a classificação de imagens histopatológicas. A transferência de conhecimento é realizada a partir de redes neurais profundas previamente treinadas para o reconhecimento de grandes conjuntos multi-classe de dados que tiveram bons resultados na classificação do conjunto para o qual foram treinados. Trabalhos recentes analisam que, essas arquiteturas de aprendizado profundo conseguem extrair informações relevantes de imagens visando melhorias nas classificações de outros classificadores que irão posteriormente, utilizar os vetores de saída gerados por essas redes como dados de treino e teste. Com base nos resultados obtidos por outros trabalhos, reproduzimos a técnica de transferência de conhecimento para a classificação de imagens histopatológicas utilizando diferentes arquiteturas para a extração de características e diferentes classificadores. O uso da transferência de conhecimento sobre a base de dados de imagens histopatológicas mostraram resultados promissores e que podem ser bem explorados a fim de trazer melhorias para a classificação automática dessa base de dados.

Palavras-chave: Aprendizado Profundo. Transferência de Conhecimento. Classificação. Imagens Histopatológicas.

ABSTRACT

In the present work, the authors make an investigation about the use of knowledge transfer applied to the classification of histopathological images. Knowledge transfer is carried out from deep neural networks previously trained for the recognition of large multi-class data sets that have had good results in the classification of the set for which they were trained. Recent work analyzes that these deep learning architectures can extract relevant information from images aiming for improvements in the classifications of other classifiers that will later use the output vectors generated by these networks as training and test data. Based on the results obtained by other works, we reproduced the technique of knowledge transfer for the classification of histopathological images using different architectures for the extraction of characteristics and different classifiers. The use of knowledge transfer on the database of histopathological images showed promising results and can be well explored in order to bring improvements to the automatic classification of this database.

Keywords: Deep Learning. Transfer Learning. Classification. Histopathological Images

LISTA DE FIGURAS

Figura 1 – ÁREAS RELACIONADAS AO ESTUDO DA VISÃO COMPUTACIONAL	15
Figura 2 – EXEMPLOS DE AMOSTRAS CONTIDAS NO CONJUNTO BREAKHIS.	22

LISTA DE TABELAS

Tabela 1 – RESUMO DOS DESCRITORES	19
Tabela 2 – DISTRIBUIÇÃO DO CONJUNTO DE DADOS POR CLASSES E FATOR DE MAGNITUDE	22
Tabela 3 – MÉDIA PERCENTUAL DOS RESULTADOS OBTIDOS NOS TESTES DOS CLASSIFICADORES	24
Tabela 4 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 40x	25
Tabela 5 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 100x	26
Tabela 6 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 200x	26
Tabela 7 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 400x	26

SUMÁRIO

1	INTRODUÇÃO	11
2	FUNDAMENTAÇÃO TEÓRICA	14
2.1	VISÃO COMPUTACIONAL	14
2.2	APRENDIZADO PROFUNDO	15
2.3	TRANSFERÊNCIA DO CONHECIMENTO	16
3	TRABALHOS RELACIONADOS	18
3.1	KNOWLEDGE TRANSFER FOR MELANOMA SCREENING WITH DEEP LEARNING	18
3.2	A DATASET FOR BREAST CANCER HISTOPATHOLOGICAL IMAGE CLASSIFICATION	19
4	CLASSIFICAÇÃO DE NÓDULOS EM EXAMES HISTOPATOLÓGICOS COM APRENDIZADO PROFUNDO	21
4.1	BASE DE DADOS	21
4.2	PRÉ-PROCESSAMENTO DA BASE DE DADOS	22
4.3	EXTRAÇÃO DE CARACTERÍSTICAS	23
4.4	TREINO E TESTE	23
5	ANÁLISE DOS RESULTADOS	25
6	CONCLUSÕES	28
	REFERÊNCIAS	29

1 INTRODUÇÃO

O câncer de mama é o tipo mais comum entre as mulheres no mundo. No Brasil corresponde a cerca de 28% dos casos de câncer em mulheres¹. No entanto, se diagnosticado e tratado precocemente, o prognóstico da doença indica boas chances de cura. A estimativa de um prognóstico de câncer envolve, tipicamente, vários médicos de diferentes especialidades, utilizando vários subconjuntos de biomarcadores e múltiplos fatores clínicos, incluindo a idade, saúde geral do paciente, a localização e o tipo de câncer, bem como o grau e o tamanho do tumor, que, mesmo para o clínico mais qualificado, pode não ser uma tarefa fácil (CRUZ; WISHART, 2006).

Neste cenário, faz-se necessário o auxílio de exames que possam desempenhar um papel importante no diagnóstico do câncer de mama, classificando e mostrando anormalidades mamárias não palpáveis e definindo a extensão dos tumores mamários (GREEN; HORTOBAGYI, 2008). Para auxiliar no diagnóstico precoce dessa doença temos a mamografia como um exame que pode identificar lesões benignas e cânceres, que geralmente se apresentam como nódulos ou calcificações.

Além da mamografia, exames histopatológicos podem ser realizados para um melhor detalhamento da lesão. Os exames histopatológicos consistem em uma biópsia realizada sobre o tecido mamário ou de parte do nódulo a fim de extrair maiores informações sobre a lesão e sobre sua natureza, também avalia características histopatológicas e moleculares da doença que podem ser usadas para prever o prognóstico e a resposta à terapia (HUNT et al., 2008). Apesar de informar um diagnóstico definitivo sobre o nódulo, a análise histopatológica é uma tarefa complexa até mesmo para patologistas experientes, assim fazendo com que a detecção automatizada do câncer de mama seja uma tarefa desafiadora.

Nesse contexto, sistemas de auxílio ao diagnóstico médico (*Computer Aided Diagnosis*, ou CAD) tem sido desenvolvidos em diversos trabalhos recentes como em (ZHU et al., 2013), (RESMINI et al., 2016) e (MENECELLI, 2013).

Em geral, os esquemas CAD fornecem opiniões extraídas de imagens médicas através de técnicas de processamento de imagens, visão computacional, inteligência artificial, reconhecimento de padrões, entre outras, a fim de prover melhorias e extrair informações que dão suporte ao diagnóstico.

Acredita-se que esquemas CAD sejam ferramentas promissoras no combate à taxa

¹ <http://www2.inca.gov.br/wps/wcm/connect/tiposdecancer/site/home/mama>

de mortalidade feminina pelo câncer de mama através de diagnósticos mais precisos com caráter preventivo (MENECELLI, 2013).

Contudo, no campo da visão computacional, a tarefa de classificação de imagens é tida como uma tarefa complexa, pois demanda o aprendizado de modelos a partir de exemplos contidos em bases de dados que forneçam exemplos categóricos. Comumente este processo de aprendizagem consiste na extração de descritores numéricos das imagens, suas características, que são utilizadas para o treinamento de classificadores.

As redes de aprendizado profundo tem se mostrado o estado da arte na tarefa de classificação de imagens (SHIN et al., 2016). Essas redes, são redes com múltiplas camadas e muitos parâmetros, na tarefa de classificação de imagens as redes neurais profundas visam aprender cada uma das etapas de extração de características das imagens com a qual é treinada.

Trabalhos recentes que fazem a classificação de imagens médicas fazem uso de redes de aprendizado profundo para detecção de diferentes tipos de câncer como pode ser visto em (MASOOD; AL-JUMAILY; ANAM, 2015) e (DEMYANOV et al., 2016) que treinam redes neurais do zero para classificação de câncer de pele.

O grande desafio no uso de redes neurais profundas em módulos CAD é o fato de as bases de dados de imagens médicas são pequenas, apresentando pouca variedade de imagens que possam ser utilizadas no treinamento dessas redes, que por possuírem inúmeros parâmetros a serem estimados, necessitam de grandes volumes de dados para que possam aprender os diferentes níveis de representação das imagens.

Contudo, como alternativa para suprir a falta de grandes volumes de dados necessário para o treinamento de redes neurais profundas uma solução que se tem mostrado promissora é a técnica de transferência de conhecimento que consiste em utilizar uma rede previamente treinada sobre uma base de dados muito grande para extrair características das imagens a serem classificadas para que essas características possam ser usadas como entrada de treinamento para diferentes classificadores como pode ser visto em (MENEGOLA et al., 2017), (SHIN et al., 2016) e (CODELLA et al., 2015) que utilizam essa técnica a fim de obter melhorias na classificação de diferentes tipos de câncer.

Este trabalho faz uso da técnica de transferência de conhecimento para a classificação de imagens histopatológicas, tendo como objetivo analisar arquiteturas de redes neurais profundas que possam trazer melhorias na tarefa de classificação dessas imagens combinadas com diferentes classificadores para que estes executem a classificação a partir dos

dados extraídos pelas arquiteturas que serão utilizadas para a realização da transferência de conhecimento.

O restante deste trabalho está organizado como segue. No Capítulo 2, é apresentada a fundamentação teórica necessária para um melhor entendimento do leitor sobre os conceitos utilizados para a execução do deste trabalho. No Capítulo 3 são apresentados os artigos que deram suporte para a execução deste trabalho e que serviram como inspiração para técnicas utilizadas no mesmo. No Capítulo 4 é dada a descrição da base de dados utilizada, do pré-processamento feito e todos os passos realizados durante a execução deste trabalho e os resultados obtidos dos testes. No Capítulo 5 é feita uma discussão sobre os resultados obtidos e comparações com o trabalho relacionado. Por fim, no Capítulo 6 apresentamos as conclusões obtidas e trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Nesta seção são abordados os conceitos necessários para o melhor entendimento teórico do leitor do contexto em que está inserido este trabalho e as técnicas utilizadas durante o processo de execução do mesmo.

2.1 VISÃO COMPUTACIONAL

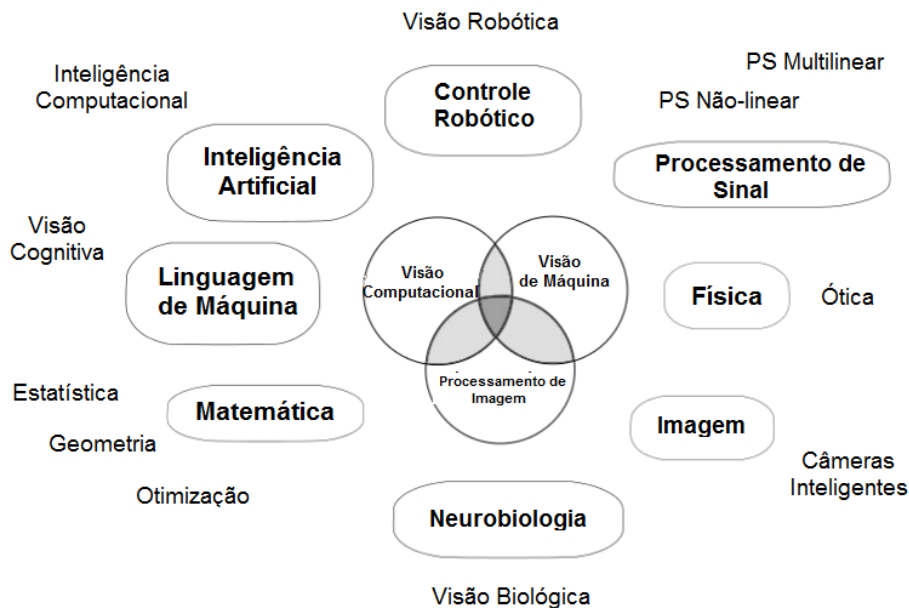
Visão computacional é o estudo da extração de informação de uma imagem, por meio da construção de descrições explícitas e claras dos objetos contidos nesta (BALLARD; BROWN, 1982). Nesse contexto, sistemas de visão computacional almejam dotar a máquina da capacidade de enxergar através de sistemas de visão artificial, podendo assim reconhecer e interpretar imagens da mesma forma, ou com maior minuciosidade, que a visão humana (FILHO; NETO, 1999).

Diversas áreas de estudo estão relacionadas à visão computacional. No campo da inteligência artificial, temos as áreas de aprendizado de máquina e de reconhecimento de padrões, que são empregadas para obter o entendimento de informações geradas a partir da imagem analisada. Outro uso importante é na robótica, em que robôs podem reconhecer objetos e obstáculos. Outros campos também relacionados são processamento de sinais, processamento de imagens e visão de máquina conforme visto na Figura 1.

Por possuir um vasto conjunto de aplicações, estudos vêm sendo desenvolvidos com a finalidade de auxiliar a melhoria da capacidade de interpretação de imagens. Isto se dá através da identificação e caracterização de anormalidades encontradas em imagens junto dos atributos que as compõem e que possam servir de parâmetros computacionais similares ao sistema visual humano (NATTKEMPER; DEGENHARD; TWELLMANN, 2007).

A medicina é uma das áreas onde o uso da visão computacional encontra uma grande gama de aplicações. Estas aplicações vão desde auxílio no tratamento de doenças e lesões, como o estudo do movimento do corpo assistido por visão computacional para ajudar pacientes com deficiências motoras, como no auxílio ao diagnóstico médico de doenças (RIOS, 2011), onde podemos aplicá-la à extração de informações e interpretação de imagens, como raio X, termografias e tomografias computadorizadas. Os dados obtidos dessas imagens podem ajudar na conclusão da opinião sobre a condição de determinado órgão, tecido, corpos de massa (como no caso de mamografias), entre outros achados relativos ao exame.

Figura 1 – ÁREAS RELACIONADAS AO ESTUDO DA VISÃO COMPUTACIONAL



Fonte: Elaborado pelo próprio autor adaptado de Rios (2011).

Desse modo, técnicas voltadas ao processamento e interpretação de imagens contribuem para a caracterização de singularidades das mesmas, assim como a obtenção de padrões a serem submetidos à classificação (MENECELLI, 2013).

2.2 APRENDIZADO PROFUNDO

As redes neurais artificiais (RNA) são um método de aprendizado de máquina criado a partir da ideia de modelar a forma de funcionamento do cérebro humano, simulando um conjunto de neurônios conectados, geralmente organizados em camadas, por onde são transmitidas as informações pela rede neural (HAYKIN et al., 2009).

Uma RNA é formada por múltiplos neurônios espalhados em camadas, nessas camadas os neurônios possuem parâmetros a serem estimados, chamados pesos sinápticos, são os pesos sinápticos que serão ajustados conforme as camadas extraem as características a partir das informações de entrada, podendo assim criar sua própria representação interna mais adequada do problema. Em um problema de classificação, essa representação é a que será usada como modelo para indicar as classes dos elementos da entrada. Devido muitos dos problemas do mundo real não serem linearmente separáveis, necessitamos de uma arquitetura com maior capacidade de representar essas informações, é aí que se insere o conceito de aprendizagem profunda.

Métodos de aprendizado profundo são métodos de aprendizagem com múltiplas

camadas de representação, obtidos pela composição de módulos simples, mas não-lineares. A aprendizagem profunda permite modelos computacionais que compõem múltiplas camadas de processamento aprender representações de dados com múltiplos níveis de abstração. Esses métodos melhoraram drasticamente o estado da arte no reconhecimento de objetos visuais, detecção de objetos e muitos outros domínios (LECUN; BENGIO; HINTON, 2015).

Um dos grandes desafios percursores que permitiu a rápida evolução das redes neurais profundas foi o **ImageNet Large Scale Visual Recognition Challenge (ILSVRC)** (RUSSAKOVSKY et al., 2015), este desafio **fez com que diversos laboratórios investigassem técnicas de aprendizado profundo afim de obter bons resultados para o reconhecimento de imagens do conjunto ImageNet**, sendo avaliados em três aspectos detecção de objetos, localização de objetos e classificação de objetos contidos nas imagens. Essa base possui milhões de imagens dos mais variados tipos, totalizando mil classes diferentes a serem reconhecidas.

Motivados por esse desafio o Visual Geometry Group **propuseram arquiteturas de redes neurais profundas**, sendo elas as redes **VGG-16, VGG-19** (SIMONYAN; ZISSERMAN, 2014), que **obtiveram bons resultados no ano de 2014**, estas arquiteturas apresentaram bom desempenho nas categorias de detecção e localização de objetos.

Já o Google buscando trazer melhorias para o âmbito de reconhecimento de imagens **propôs a rede InceptionV3** (SZEGEDY et al., 2016) uma arquitetura voltada para a resolução de **problemas de visão computacional**, e que teve seu treino realizado com o intuito de reconhecer **elementos da base de dados ImageNet onde apresentaram bom desempenho no ano de 2015**. Outro fator importante da rede InceptionV3 foi a redução de parâmetros estimados pela rede, fazendo com que ela possuía melhor desempenho computacional em relação as redes VGG durante seu treino (SZEGEDY et al., 2016).

Neste trabalho faremos uso dessas três arquiteturas de redes neurais profundas apresentadas, utilizando-as como geradoras de descritores da base de dados BreaKhis, sendo que a VGG-16 e VGG-19 geram vetores de dimensão 4096 e a rede InceptionV3 gera um vetor descritores de tamanho 2048.

2.3 TRANSFERÊNCIA DO CONHECIMENTO

Visando reduzir o tempo gasto treinando grandes modelos de aprendizado profundo do zero além de tentar suprir a falta de grandes conjuntos de dados para o treinamento desses modelos a solução encontrada foi a de reciclar o conhecimento de modelos previamente treinados

com grande volume de dados (MENEGOLA et al., 2017). Essa reciclagem de conhecimento dos modelos é conhecida como transferência de conhecimento.

A transferência de conhecimento para a classificação de imagens consiste em usar os vetores de características gerados por uma rede neural profunda previamente treinada com seus pesos sinápticos configurados para reconhecer e extrair características de um determinado conjunto de dados para o qual foi previamente treinado, esses vetores gerados serão os descritores de cada imagem presente na base de dados. Após gerados esses vetores de características do novo conjunto do qual se deseja fazer a classificação, esses vetores podem ser utilizados como entrada para um novo classificador para que seja treinado com esses vetores ou podem ser dados como entrada para a camada completamente conectada de classificação da própria arquitetura que foi utilizada para extração das características (YOSINSKI et al., 2014).

Podemos exemplificar o processo de transferência de conhecimento como uma pessoa que está vendo um objeto e começa a descrever os elementos presentes neste objeto para outra pessoa, onde esta segunda pessoa não está vendo o objeto descrito, a partir das características ditas pela primeira pessoa o ouvinte irá traçar um perfil dos elementos que ele conhece e das características recebidas da primeira pessoa e associar a um objeto que ele conhece e que possua características semelhantes.

Como observado por (MENEGOLA et al., 2017) e (SHIN et al., 2016) a transferência de conhecimento tem mostrado bons resultados e é uma alternativa muito vantajosa, pois dispensa o tempo que seria gasto treinando uma rede neural robusta do zero para um domínio específico.

3 TRABALHOS RELACIONADOS

3.1 KNOWLEDGE TRANSFER FOR MELANOMA SCREENING WITH DEEP LEARNING

Em (MENEGOLA et al., 2017) os autores exploram o estado da arte na tarefa de classificação de imagem, que consiste no uso de arquiteturas baseadas em aprendizado profundo para a realização de transferência de conhecimento, onde redes de aprendizado profundo com seus pesos sinápticos previamente treinados para o reconhecimento de outro conjunto de dados é utilizada para extrair características de um novo conjunto desconhecido para a rede e utilizar os vetores de características gerados como entrada para outros modelos de classificadores, que serão treinados com esses dados.

Em seu trabalho (MENEGOLA et al., 2017) ignora todos os passos comumente usados no pré-processamento de imagens, como a segmentação, assim podendo analisar o impacto da transferência de conhecimento e o quanto essa técnica ajuda na tarefa de reconhecimento de lesões de pele e o quanto o conjunto utilizado para o treino prévio da arquitetura da qual será realizado a transferência influência nos resultados obtidos. Para isso a transferência foi realizada a partir de redes treinadas com duas bases distintas, uma das bases utilizadas foi a base médica *Diabetic Retinopathy Detection dataset (Retinopathy)*¹ e a base *ImageNet Large Scale Visual Recognition Challenge 2012 dataset* de imagens gerais (*ImageNet*) que possui 1000 classes de imagens distintas.

Sobre o conjunto de dados foi necessário a utilização da técnica de *data augmentation* pela pouca quantidade de dados disponíveis da base foco de seu trabalho. Com esta técnica também foi possível balancear a base com os tipos de lesões que seriam mais interessantes para a classificação.

Os testes foram realizados com duas arquiteturas, VGG-M e VGG-16, a fim de avaliar o quanto o número de camadas iria influenciar nos resultados de forma que a camada de classificação destas arquiteturas foi substituída por um classificador Support Vector Machine (SVM) para fazer a decisão a partir dos dados gerados das arquiteturas utilizadas. Os testes apresentaram melhorias quando a rede neural era treinada para reconhecer as imagens da base *ImageNet* e era aplicado o *fine-tuning*, que consiste no re-treino da rede neural sobre a base de dados de lesões de pele, obtendo assim bons resultados em relação ao treino realizado com as

¹ <https://www.kaggle.com/c/diabetic-retinopathy-detection/data>

imagens médicas do conjunto *Retinopathy*.

Como conclusão de seu trabalho (MENEGOLA et al., 2017) afirma que o uso de *fine-tuning* é algo necessário para a melhoria dos classificadores, trazendo grande impacto quando utilizado. Outra observação feita foi que a arquitetura VGG-16 por ser mais profunda teve melhor performance em extrair características que obtiveram melhor separação pelo SVM. E por último o melhor protocolo a ser seguido para um melhor desempenho foi utilizar uma arquitetura profunda com pesos sinápticos ajustados para o reconhecimento do conjunto Imagenet utilizando *fine-tuning* já que o treino utilizando uma base de dados relacionada não obteve nenhum resultado satisfatório mesmo na transferência dupla aplicada com *fine-tuning*.

3.2 A DATASET FOR BREAST CANCER HISTOPATHOLOGICAL IMAGE CLASSIFICATION

Em (SPANHOL et al., 2016), o autor nos apresenta a base *BreaKhis*, uma base de imagens histopatológicas geradas a partir da análise microscópica feita por patologistas de nódulos mamários. Tendo como objetivo mostrar a dificuldade do problema de classificação desse tipo de imagem os autores realizam testes sobre a base de dados utilizando diferentes algoritmos de extração de características de imagens e classificadores baseados em modelos de aprendizado de máquina.

Considerando duas principais formas de extrair características de imagens sendo uma delas a segmentação que é um processo que não é considerado trivial para imagens histopatológicas e características globais baseadas na textura, o autor optou por utilizar descritores baseados em textura sendo eles *local binary patterns* (LBP), *completed LBP* (CLBP), *local phase quantization* (LPQ), *gray-level co-occurrence matrix* (GLCM), *parameter-free threshold adjacency statistics* (PFTAS) e *Oriented FAST and Rotated BRIEF* (ORB) a Tabela 1 apresenta a quantidade de características geradas por cada um dos algoritmos listados.

Tabela 1 – RESUMO DOS DESCRITORES

Método	Quantidade de Características
CLBP	1352
GLCM	13
LBP	10
LPQ	256
ORB	32
PFTAS	162

Os algoritmos de extração de características das imagens foram testado com diferentes tipos de classificadores sendo eles *1-Nearest Neighbour* (1-NN), *quadratic linear analysis* (QDA), support vector machine (SVM) e *Random Forest of decision trees* (RF). Dentre os classificadores utilizados o 1-NN foi utilizado com a finalidade de discriminar a relevância das características utilizadas, o SVM foi testado com vários kernels, sendo o Gaussiano o que obteve melhor resultados.

Na etapa de teste (SPANHOL et al., 2016) dividiu o conjunto e 70% para treino e 30% para teste, a métrica utilizada para o resultado obtido consistiu na média do percentual de acertos de 5 testes realizados com os classificadores.

Ao apresentar os resultados obtidos o autor faz uma análise de como a magnitude das imagens estão influenciando nos testes foi observado que as diferentes magnitudes apresentadas na base de dados não carregam a mesma quantidade de informações relevantes para o aprendizado dos classificadores, no caso das imagens com magnitude 40x e 200x apresentaram bons resultados dos classificadores, sendo elas foco para outras investigações do trabalho.

Um outro ponto analisado pelo autor foi a influência dos descritores das imagens e como eles influenciaram nos resultados obtidos, no geral os resultados pareceram estáveis e com valores próximos, mas o descritor PFTAS teve a melhor performance entre os demais apesar de pouca diferença entre os resultados mesmo sabendo que esses resultados também possuem um pouco de influência dos classificadores utilizados.

Tendo feito essas observações (SPANHOL et al., 2016) explorou seus melhores resultados, que foi a combinação do classificador SVM e o descritor PFTAS no conjunto de magnitude 200x. Para entender melhor este resultado foi gerada uma matriz de confusão que teve como resposta a ocorrência de muitos falsos negativos que estavam ocorrendo por conta de imagens do conjunto benigno do subconjunto do tipo Fibroadenoma faziam com que o classificador não obtivesse uma melhor performance.

4 CLASSIFICAÇÃO DE NÓDULOS EM EXAMES HISTOPATOLÓGICOS COM APRENDIZADO PROFUNDO

Nesta seção são apresentados todos os passos de implementação que foram realizados, bem como informações sobre a base de dados utilizada, seu pré-processamento e as tecnologias utilizadas para a execução deste trabalho. Todos procedimentos aqui descritos foram realizados em uma máquina com processador Intel core i5-3470 3.20GHz com 8GB de memória RAM, os códigos foram escritos utilizando a linguagem python em sua versão 3.6.2 e documentado através do jupyter notebook. A biblioteca utilizada para o carregamento das redes utilizadas e seus respectivos pesos sinápticos ajustados para o reconhecimento do conjunto *ImageNet* foi a biblioteca Keras¹, que também possui suporte para o carregamento e pré-processamento das imagens que foram utilizadas pelas redes neurais. Todos os procedimentos e implementações aqui descritos estão disponíveis para reprodução².

4.1 BASE DE DADOS

Motivados pela falta de dados para treino e validação de classificadores Spanhol et al. (2016) com ajuda do Laboratório P&D³ construíram a **base de dados *BreaKhis***. Essa base contém **imagens de biópsias feitas a partir da extração de nódulos de 82 pacientes diferentes, onde as imagens geradas a partir da análise histopatológica são classificadas como tumores malignos ou benignos** como mostrado na Figura 2, A Figura 2 (a) é uma amostra real benigna de magnitude 40x contida no conjunto e a Figura 2 (b) é uma amostra real maligna de magnitude 40x contida no conjunto, essas imagens possuem diferentes ordens de magnitudes, ampliações feitas através da análise no microscópio, sendo essas magnitudes 40x, 100x, 200x, 400x, distribuídas conforme a Tabela 2.

As amostras para análise foram obtidas através de biópsia cirúrgica e foram validadas por patologistas especializados com auxilio de exames complementares, garantindo assim a veracidade dos dados (SPANHOL et al., 2016). Além da análise de maligno ou benigno esses tumores também podem ser classificados em alguns subtipos diferentes, no caso de tumores benignos o conjunto de dados apresenta 4 subtipos: adenosis (A), fibroadenoma (F), phyllodes (PT) e tubular adenoma (TA). Para os casos de tumores malignos o conjunto apresenta 4 subtipos: ductal carcinoma (DC), lobular carcinoma (LC), mucinous carcinoma (MC) e papillary carcinoma

¹ <https://keras.io/>

² <https://github.com/DecioAguiar/histopathological-transfer>

³ <http://www.prevencaoediagnose.com.br/>




Figura 2 – EXEMPLOS DE AMOSTRAS CONTIDAS NO CONJUNTO BREAKHIS.
Fonte: (SPANHOL et al., 2016)

(PC). Apesar dessa base apresentar múltiplas classes para tipos de tumores, iremos utilizar apenas a classificação entre malignos e benignos.

Tabela 2 – DISTRIBUIÇÃO DO CONJUNTO DE DADOS POR CLASSES E FATOR DE MAGNITUDE

Magnitude	Benigno	Maligno	Total
40x	625	1370	1995
100x	644	1437	2081
200x	623	1390	2013
400x	588	1232	1820

Fonte: Elaborado pelo próprio autor adaptado de (SPANHOL et al., 2016)

4.2 PRÉ-PROCESSAMENTO DA BASE DE DADOS

Na etapa de pré-processamento dos dados, para que as imagens pudessem ser passadas como entrada das redes neurais que fariam a extração de características das mesmas, foi necessário realizar o redimensionamento das imagens, já que a dimensão original das imagens é de 700x460 pixels.

Para que pudesse ser feito o redimensionamento das imagens de forma que se adequassem a camada de entrada das redes neurais, utilizamos a biblioteca *Keras* que contém métodos de pré-processamento de imagens, os quais foram utilizados para realizar o carregamento dos diretórios que continham a base de dados e foram gerados os rótulos das imagens conforme o diretório em que as imagens se encontravam. Neste trabalho, usamos dois diretórios um para armazenar as imagens benignas e outro com as malignas. Esse processo foi realizado para cada uma das magnitudes contidas na base de dados. No processo de redimensionamento das imagens para que pudessem se adequar a camada de entrada da arquitetura *inceptionV3* as dimensões das

imagens foram redimensionadas para 299x299 pixels. Para a arquitetura VGG-16 e VGG-19 as dimensões das imagens foram redimensionadas para 224x224 pixels.

4.3 EXTRAÇÃO DE CARACTERÍSTICAS

Tendo sido realizado o redimensionamento das imagens conforme as especificações de entrada de cada uma das arquiteturas utilizadas, as imagens se tornaram aptas para que pudesse ser realizado a extração de características, para isso utilizamos a biblioteca Keras para realizar a extração de características das imagens. O Keras é uma API de alto nível para o uso de redes neurais profundas que pode ser executada sobre o Tensorflow⁴ ou Theano⁵, que são bibliotecas voltadas para a implementação de redes neurais profundas.

A biblioteca Keras permite de forma fácil e rápida o carregamento das arquiteturas de redes neurais com seus pesos sinápticos ajustados para o reconhecimento do conjunto *ImageNet*. Uma outra facilidade permitida pelo Keras é o fato de que ele possibilita o carregamento dessas arquiteturas sem a camada de classificação, já que só estávamos interessados nas camadas que fazem a extração de características dos conjuntos de imagens.

Carregamos através do Keras as arquiteturas InceptionV3, VGG-16 e VGG-19, cada uma configurada com os pesos sinápticos para o reconhecimento do conjunto *ImageNet*⁶. Para cada magnitude foram gerados os vetores de características com base no modelo interno de extração de características de cada arquitetura utilizada. Tendo sido realizada a extração, os elementos dos conjuntos precisaram passar por um rearranjo pois os vetores de saída gerados pelas redes neurais profundas utilizadas são tensores de ordem 4 e os classificadores que foram treinados com essas descrições geradas das imagens só recebem como entrada tensores de ordem 2, que são vetores aceitos como entrada desses classificadores.

4.4 TREINO E TESTE

Após realizada a extração de características das imagens utilizando cada uma das arquiteturas (*InceptionV3*, VGG-16 e VGG-19), foi realizado a transferência de conhecimento, que consistiu no uso dos descritores gerados pelas redes neurais profundas como entrada para treino e teste de outros classificadores.

⁴ <http://tensorflow.org/>

⁵ <http://deeplearning.net/software/theano/>

⁶ <http://www.image-net.org/>

Os classificadores utilizados para testar a eficiência da transferência de conhecimento foram o classificador SVM com kernel linear, por ter apresentado melhores resultados em testes prévios, 1-NN, QDA e RF, todos eles sendo classificadores disponíveis na biblioteca de aprendizado de máquina *scikit-learn* (PEDREGOSA et al., 2011).

A métrica utilizada foi a obtenção da média percentual de cinco experimentos utilizando cada um dos classificadores. Para a realização dos testes foram selecionadas aleatoriamente 70% das amostras para treino e 30% para teste, de forma semelhante ao que foi feito por (SPANHOL et al., 2016) com o objetivo de mesclar as amostras e que imagens advindas de um mesmo paciente não fossem utilizadas em ambas as partições de treino e teste. A Tabela 3 apresenta o valor percentual médio de acurácia obtido por cada classificador e para cada uma das arquiteturas utilizadas. Os símbolos "*" presentes na Tabela 3 indicam que não houve teste realizado para a determinada magnitude e classificador.

Tabela 3 – MÉDIA PERCENTUAL DOS RESULTADOS OBTIDOS NOS TESTES DOS CLASSIFICADORES

Arquitetura	Classificadores	Magnitude			
		40x	100x	200x	400x
VGG-16	SVM	86 \pm 0.1	86 \pm 0.0	85 \pm 0.4	83 \pm 0.3
	RF	74 \pm 0.3	76 \pm 0.2	76 \pm 0.2	71 \pm 0.5
	1-NN	75 \pm 0.3	75 \pm 0.2	76 \pm 0.3	73 \pm 0.2
	QDA	32 \pm 0.2	32 \pm 0.1	32 \pm 0.2	33 \pm 0.3
VGG-19	SVM	83 \pm 0.3	84 \pm 0.3	84 \pm 0.2	82 \pm 0.3
	RF	72 \pm 0.2	73 \pm 0.3	75 \pm 0.3	72 \pm 0.2
	1-NN	75 \pm 0.3	75 \pm 0.1	76 \pm 0.3	71 \pm 0.2
	QDA	32 \pm 0.2	32 \pm 0.1	32 \pm 0.2	33 \pm 0.3
InceptionV3	SVM	90 \pm 0.1	88 \pm 0.2	87 \pm 0.2	87 \pm 0.2
	1-NN	*	*	*	*
	QDA	*	*	*	*
	RF	*	*	*	*

Na Seção 5 é apresentado com detalhes as discussões sobre os resultados obtidos pelos classificadores em cada uma das magnitudes e a influência das arquiteturas utilizadas no desempenho obtido pelos classificadores.

5 ANÁLISE DOS RESULTADOS

Ao analisarmos os resultados obtidos, alguns aspectos foram observados, um deles foi como a profundidade da rede influencia nos resultados obtidos pelos classificadores que recebem a transferência de conhecimento. Em seu trabalho (MENEGOLA et al., 2017) observou que redes com maior profundidade obtiveram melhores resultados que redes com menor profundidade. Em nossos experimentos os classificadores que foram treinados utilizando as características extraídas pela rede VGG-16 obtiveram melhores resultados que os classificadores treinados com as características extraídas utilizando a rede VGG-19, consideramos essa observação interessante, pois foi contrária ao que foi observado em outros trabalhos. Já a rede InceptionV3 conseguiu atingir bons resultados combinada ao classificador SVM.

Uma outra observação feita está relacionada com o fato de que os classificadores SVM que receberam a transferência de conhecimento da rede VGG-16 possuíam melhor performance na classificação das bases com magnitude 40x e 100x, ambas com precisão parecidas, diferentes dos resultados obtidos por (SPANHOL et al., 2016) que obteve grandes acertos sobre a base de magnitude 200x.

As Tabelas 4 a 7 mostram o comparativo dos melhores resultados obtidos por esse trabalho e do trabalho de (SPANHOL et al., 2016) para cada um dos classificadores utilizados nos testes sobre a base de dados, os resultados exibidos são as médias percentuais dos testes realizados.

Tabela 4 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 40x

Magnitude 40x	(SPANHOL et al., 2016)	VGG-16	VGG-19	InceptionV3
SVM	81.6±3.0	86 ±0.1	83 ±0.3	90 ±0.1
RF	81.8 ±2.0	74 ±0.3	72 ±0.2	*
1-NN	80.9 ±2.0	75 ±0.3	75 ±0.3	*
QDA	83.9 ±4.1	32 ±0.2	32 ±0.2	*

Na Tabela 4 podemos observar que a rede VGG-16 tem resultado superior a rede VGG-19 e aos valores obtidos por (SPANHOL et al., 2016) para o classificador SVM, mas apesar de obter bons resultados para o classificador SVM. Para os demais classificadores tivemos uma queda de desempenho.

Na Tabela 5 mais uma vez podemos observar melhor performance da VGG-16 em relação a VGG-19, perdendo apenas para a rede InceptionV3, mas a diferença obtida no testes das duas foi pequena quando feito com o classificador SVM, outro fator interessante foi o fato

Tabela 5 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 100x

Magnitude 100x	(SPANHOL et al., 2016)	VGG-16	VGG-19	InceptionV3
SVM	79.9 \pm 5.4	86 \pm 0.0	84 \pm 0.3	88 \pm 0.2
RF	81.3 \pm 2.8	76 \pm 0.2	73 \pm 0.3	*
1-NN	80.7 \pm 2.4	75 \pm 0.2	75 \pm 0.1	*
QDA	82.1 \pm 4.9	32 \pm 0.1	32 \pm 0.1	*

de não existir desvio por parte do classificador SVM combinado com a rede VGG-16.

Tabela 6 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 200x

Magnitude 200x	(SPANHOL et al., 2016)	VGG-16	VGG-19	InceptionV3
SVM	85.1 \pm 3.1	85 \pm 0.4	84 \pm 0.2	87 \pm 0.2
RF	83.5 \pm 2.3	76 \pm 0.2	75 \pm 0.3	*
1-NN	83.4 \pm 3.3	76 \pm 0.3	76 \pm 0.3	*
QDA	84.2 \pm 4.1	32 \pm 0.2	32 \pm 0.2	*

Na Tabela 6 nos resultados obtidos com o classificador SVM não conseguimos melhorias relevantes em relação ao resultado obtido por (SPANHOL et al., 2016), como já investigado pelo autor em seu trabalho esse conjunto apresenta um forte falso negativo sobre os dados do tipo Fibroadenoma impedindo melhores performances dos algoritmos utilizados.

Tabela 7 – COMPARAÇÃO DOS RESULTADOS OBTIDOS COM MAGNITUDE 400x

Magnitude 400x	(SPANHOL et al., 2016)	VGG-16	VGG-19	InceptionV3
SVM	82.3 \pm 3.8	83 \pm 0.3	82 \pm 0.3	87 \pm 0.2
RF	81.0 \pm 3.8	71 \pm 0.5	72 \pm 0.2	*
1-NN	81.7 \pm 3.3	73 \pm 0.2	71 \pm 0.2	*
QDA	82.0 \pm 5.9	33 \pm 0.3	33 \pm 0.3	*

Na Tabela 7 semelhante ao que ocorreu com os testes sobre o conjunto de magnitude 200x os resultados obtidos por esse trabalho foram semelhantes ao trabalho comparativo, tendo pouco destaque para a rede InceptionV3 que apresentou pouca melhoria em relação aos demais.

Em geral, um fenômeno que permaneceu constante foram os resultados obtidos pelos classificadores QDA, 1-NN e RF pois não apresentaram melhoria em sua performance na classificação das diferentes magnitudes, diferente do classificador SVM, que obteve melhoria em relação ao trabalho comparado e obteve menor desvio padrão, mostrando uma melhor estabilidade do modelo. Já os resultados obtidos pela rede InceptionV3 tiveram grande destaque juntamente ao classificador SVM, uma justificativa para os bons resultados dessa rede se deve ao fato de que a dimensão das imagens de entrada fazem com que a rede possua maiores informações que

podem ser extraídas durante o processo de extração de características, obtendo assim melhores resultados.

6 CONCLUSÕES

Neste trabalho tivemos como objetivo analisar a técnica de transferência de conhecimento a partir de redes neurais profundas treinadas para o reconhecimento do conjunto ImageNet, e como a profundidade destas redes influencia nos resultados obtidos por classificadores que receberam como dado de treino os vetores de características gerados a partir da extração feita por essas redes neurais previamente treinadas. Estes experimentos nos permitiram concluir que a transferência de conhecimento é uma boa técnica a ser explorada, pois apresentou bons resultados em comparação a resultados internos e externos obtidos para o classificador SVM, mas diferente do que foi observado por (MENEGOLA et al., 2017) uma rede com menor profundidade permitiu ter melhores resultados que uma rede com mais camadas profundas. Outra conclusão que pudemos ter foi que quanto mais se preservar dados das imagens originais como é o caso da rede InceptionV3 que tem como entrada maiores dimensões de imagem, permite melhores resultados. Como **trabalhos futuros** pretendemos **explorar melhor o desempenho da transferência de conhecimento feita a partir de bases de dados correlatas, em nosso caso bases médicas, e utilizar as técnicas de *fine-tuning* e *data augmentation* a fim de melhorar os modelos gerados pelas redes profundas avaliadas.**

REFERÊNCIAS

- BALLARD, D. H. D. H.; BROWN, C. M. **Computer vision**. [S.l.], 1982.
- CODELLA, N.; CAI, J.; ABEDINI, M.; GARNAVI, R.; HALPERN, A.; SMITH, J. R. Deep learning, sparse coding, and svm for melanoma recognition in dermoscopy images. In: SPRINGER. **International Workshop on Machine Learning in Medical Imaging**. [S.l.], 2015. p. 118–126.
- CRUZ, J. A.; WISHART, D. S. Applications of machine learning in cancer prediction and prognosis. **Cancer informatics**, Libertas Academica Ltd, v. 2, 2006.
- DEMYANOV, S.; CHAKRAVORTY, R.; ABEDINI, M.; HALPERN, A.; GARNAVI, R. Classification of dermoscopy patterns using deep convolutional neural networks. In: IEEE. **Biomedical Imaging (ISBI), 2016 IEEE 13th International Symposium on**. [S.l.], 2016. p. 364–368.
- FILHO, O. M.; NETO, H. V. **Processamento digital de imagens**. [S.l.: s.n.], 1999.
- GREEN, M. C.; HORTOBAGYI, G. N. Chemotherapy for breast cancer. In: _____. **Breast Cancer 2nd edition**. New York, NY: Springer New York, 2008. p. 345–385. ISBN 978-0-387-34952-7. Disponível em: <http://dx.doi.org/10.1007/978-0-387-34952-7_12>.
- HAYKIN, S. S.; HAYKIN, S. S.; HAYKIN, S. S.; HAYKIN, S. S. **Neural networks and learning machines**. [S.l.]: Pearson Upper Saddle River, NJ, USA:, 2009. v. 3.
- HUNT, K. K.; ROBB, G. L.; STROM, E. A.; UENO, N. T. Breast cancer 2nd edition. In: **Breast Cancer 2nd edition**. [S.l.]: Springer, 2008.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, Nature Publishing Group, v. 521, n. 7553, p. 436–444, 2015.
- MASOOD, A.; AL-JUMAILY, A.; ANAM, K. Self-supervised learning model for skin cancer diagnosis. In: IEEE. **Neural Engineering (NER), 2015 7th International IEEE/EMBS Conference on**. [S.l.], 2015. p. 1012–1015.
- MENECELLI, R. C. **Caracterização de sinais secundários em imagens mamográficas por redes neurais artificiais para auxílio ao diagnóstico do câncer de mama**. Tese (Doutorado) — Universidade de São Paulo, 2013.
- MENEGOLA, A.; FORNACIALI, M.; PIRES, R.; BITTENCOURT, F. V.; AVILA, S.; VALLE, E. Knowledge transfer for melanoma screening with deep learning. **arXiv preprint arXiv:1703.07479**, 2017.
- NATTKEMPER, T. W.; DEGENHARD, A.; TWELLMANN, T. **Breast Tumor Classification and Visualization with Machine-learning Approaches-2**. [S.l.: s.n.], 2007.
- PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V. et al. Scikit-learn: Machine learning in python. **Journal of Machine Learning Research**, v. 12, n. Oct, p. 2825–2830, 2011.

- RESMINI, R.; ARAÚJO, A. d. S.; NANTES, O. B.; ARAÚJO, C.; CONCI, A. Classificação digital de diagnósticos da mama baseado em imagens térmicas. **Anais da Escola Regional de Informática da Sociedade Brasileira de Computação (SBC)–Regional de Mato Grosso**, v. 1, n. 7, 2016.
- RIOS, L. R. S. Visão computacional. **Universidade Federal da Bahia, Salvador, BA**, 2011.
- RUSSAKOVSKY, O.; DENG, J.; SU, H.; KRAUSE, J.; SATHEESH, S.; MA, S.; HUANG, Z.; KARPATY, A.; KHOSLA, A.; BERNSTEIN, M. et al. Imagenet large scale visual recognition challenge. **International Journal of Computer Vision**, Springer, v. 115, n. 3, p. 211–252, 2015.
- SHIN, H.-C.; ROTH, H. R.; GAO, M.; LU, L.; XU, Z.; NOGUES, I.; YAO, J.; MOLLURA, D.; SUMMERS, R. M. Deep convolutional neural networks for computer-aided detection: Cnn architectures, dataset characteristics and transfer learning. **IEEE transactions on medical imaging**, IEEE, v. 35, n. 5, p. 1285–1298, 2016.
- SIMONYAN, K.; ZISSERMAN, A. Very deep convolutional networks for large-scale image recognition. **arXiv preprint arXiv:1409.1556**, 2014.
- SPANHOL, F. A.; OLIVEIRA, L. S.; PETITJEAN, C.; HEUTTE, L. A dataset for breast cancer histopathological image classification. **IEEE Transactions on Biomedical Engineering**, IEEE, v. 63, n. 7, p. 1455–1462, 2016.
- SZEGEDY, C.; VANHOUCKE, V.; IOFFE, S.; SHLENS, J.; WOJNA, Z. Rethinking the inception architecture for computer vision. In: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition**. [S.l.: s.n.], 2016. p. 2818–2826.
- YOSINSKI, J.; CLUNE, J.; BENGIO, Y.; LIPSON, H. How transferable are features in deep neural networks? In: **Advances in neural information processing systems**. [S.l.: s.n.], 2014. p. 3320–3328.
- ZHU, M.; XU, C.; YU, J.; WU, Y.; LI, C.; ZHANG, M.; JIN, Z.; LI, Z. Differentiation of pancreatic cancer and chronic pancreatitis using computer-aided diagnosis of endoscopic ultrasound (eus) images: a diagnostic test. **PloS one**, Public Library of Science, v. 8, n. 5, p. e63820, 2013.